

Metrics Analysis

yao

2026 年 8 月

目錄

- 1 執行環境
- 2 品質評分規則
- 3 人工 Top 100 參考集
- 4 訓練與驗證資料
- 5 模型架構與超參數
- 6 VGG16、ResNet18、ResNet50 訓練與排序流程
- 7 Top 100 與人工參考集比較
- 8 圖片案例差異分析
- 9 結論
- 10 AI 工具使用說明

1 執行環境

沿用前一階段成功的 TWCC GPU 執行環境。為避免家目錄 Miniforge 或 ~/.local PyTorch 造成 CUDA 相容性問題，使用 NVIDIA PyTorch 24.08 容器內建的 PyTorch，並透過 `venv --system-site-packages` 建立 `unit7_ngc` 環境。GPU 通過標準不僅確認 `torch.cuda.is_available()`，亦實際建立 CUDA tensor 並執行矩陣乘法。

表 1：實驗執行環境

項目	設定
平台	TWCC GPU 容器
容器映像	pytorch-24.08-py3:latest
Python	Python 3.10
PyTorch	2.5.0a0+872d972e41.nv24.08
CUDA Runtime	12.6
GPU	NVIDIA Tesla V100-SXM2-32GB
虛擬環境	unit7_ngc (<code>venv --system-site-packages</code>)
實驗紀錄	Weights & Biases (<code>training-unit7-ranking</code>)

GPU 測試方式：

```
import torch
x = torch.randn(1024, 1024, device="cuda")
y = x @ x
torch.cuda.synchronize()
print(y.device) # cuda:0
```

2 品質評分規則

每張圖片依五項標準給予連續分數，總分為 0 至 100，作為 regression 模型的 `quality_score`。分數越高代表圖片越適合作為道路與障礙資訊辨識之高品質樣本。

表 2：影像品質評分標準

評分項目	分數範圍	判定重點
道路資訊完整度	0-25	道路輪廓、車道與可行駛區域是否完整可辨
障礙物資訊完整度	0-25	落石、火焰、車輛或其他障礙物是否清楚可辨
清晰度	0-20	模糊程度、細節與物件邊界是否清楚
曝光	0-20	亮度、對比與光線是否自然且保留細節
真實應用合理性	0-10	場景是否接近實際道路拍攝與應用需求
<code>quality_score</code>	0-100	上述五項分數總和

此評分方式延續前一份二分類作業的人工判定概念，利用品質差異作為連續排序目標。

3 人工 Top 100 參考集

人工參考集固定為 100 張。僅作為最終 Ranking 評估基準

表 3：資料用途與隔離方式

資料集	用途	張數
Train	Regression 訓練	320
Validation	選擇最佳 checkpoint	80
Human Reference	最終 Top 100 比較	100

4 訓練與驗證資料

本次直接沿用固定的 320 張訓練集、80 張驗證集與 100 張人工參考集。Train 與 Validation 均包含 quality_score，人工 Top 100 則只在最終評估階段使用。三個模型的完整推論集合由程式在記憶體中合併三份 CSV，合計 500 張；未額外建立 candidate_pool.csv。

表 4：訓練、驗證與人工參考資料分布

資料集	張數	是否參與訓練	是否參與最終人工比較
Train	320	是	否
Validation	80	否（僅驗證）	否
Human Reference	100	否	是
合計	500	-	-

5 模型架構與超參數

本實驗比較三種 ImageNet 預訓練模型：VGG16、ResNet18 與 ResNet50。三者使用相同資料切分、資料前處理及 Regression 設定，最後一層均修改為單一 scalar 輸出。訓練時將 0-100 的 quality_score 正規化至 0-1，使用 SmoothL1Loss 最佳化；推論時再轉回 0-100 分。

表 5：模型與共用超參數

項目	設定
模型	VGG16、ResNet18、ResNet50
預訓練	ImageNet 預訓練權重
任務	Continuous Regression
輸出	單一 quality score（越高越好）
輸入尺寸	224 × 224
Optimizer	AdamW
Learning rate	1×10^{-4}
Weight decay	1×10^{-4}
Batch size	32
最大 epoch	30
Early stopping patience	5
Loss function	SmoothL1Loss
最佳模型選擇	最低 validation loss
Random seed	42

三個正式 W&B run 名稱如下：

- ranking_resnet18_regression_lr1e-4_bs32
- ranking_vgg16_regression_lr1e-4_bs32
- ranking_resnet50_regression_lr1e-4_bs32

6 VGG16、ResNet18、ResNet50 訓練與排序流程

三個模型皆完成正式訓練並保存最佳 checkpoint：resnet18_best.pt、vgg16_best.pt 與 resnet50_best.pt。最佳權重由 validation loss 決定，而非最後一個 epoch。訓練完成後，三個模型均對完整 500 張圖片產生 raw_quality_score，再以固定的 Test-Time Augmentation (TTA) 計算平均分數與標準差，建立 confidence-adjusted score。

Confidence-adjusted score 使用 TTA 標準差作為不確定度；不確定度先正規化至 0-1，再以 $\text{quality} \times (1 - \text{normalized uncertainty})$ 修正。Ensemble 則先將三模型 Raw score 各自 Min-Max 正規化，再取平均。

表 6：七種最終排名方法

排名方法	說明
VGG16 Raw	VGG16 直接輸出的品質分數
ResNet18 Raw	ResNet18 直接輸出的品質分數
ResNet50 Raw	ResNet50 直接輸出的品質分數
VGG16 Confidence	VGG16 TTA 不確定度修正後分數
ResNet18 Confidence	ResNet18 TTA 不確定度修正後分數
ResNet50 Confidence	ResNet50 TTA 不確定度修正後分數
Ensemble	三模型正規化 Raw score 的平均

7 Top 100 與人工參考集比較

每一種方法皆對完整 500 張圖片依分數由高至低排序並取前 100 張。人工參考集記為 H，模型 Top 100 記為 M。Intersection 為 $|H \cap M|$ ；Overlap = $|H \cap M|/100$ ；Jaccard = $|H \cap M|/|H \cup M|$ 。Average Precision (AP) 則使用完整 500 張的連續模型分數計算，人工 Top 100 視為 relevant=1，其餘 400 張為 relevant=0。

表 7：七種方法與人工 Top 100 的比較結果

Method	Intersection	Overlap	Jaccard	AP
VGG16 Raw	24	0.2400	0.1364	0.2674
ResNet18 Confidence	18	0.1800	0.0989	0.2192
VGG16 Confidence	21	0.2100	0.1173	0.2176
ResNet18 Raw	18	0.1800	0.0989	0.1949
Ensemble	14	0.1400	0.0753	0.1871
ResNet50 Confidence	13	0.1300	0.0695	0.1740
ResNet50 Raw	13	0.1300	0.0695	0.1702

七種方法中，VGG16 Raw 在 Intersection、Overlap、Jaccard 與 AP 四項指標皆為最高，與人工 Top 100 共有 24 張相同，Overlap 為 0.24、Jaccard 為 0.1364、AP 為 0.2674。因此本報告將 VGG16 Raw 視為主要 Ranking 方法。

Confidence adjustment 並非對所有模型都有幫助。ResNet18 的 AP 由 Raw 0.1949 提升至 Confidence 0.2192，但 Top 100 Overlap 維持 0.18；相反地，VGG16 經 Confidence 修正後 Overlap 由 0.24 降為 0.21，AP 由 0.2674 降為 0.2176。

Ensemble 的 AP 為 0.1871，低於 VGG16 Raw，表示單純平均三模型分數會稀釋 VGG16 原本較接近人工排序的訊號。ResNet50 在 Raw 與 Confidence 下的 Intersection 均為 13，顯示本次資料上其排序與人工偏好的一致性最低。

8 圖片案例差異分析

由於 VGG16 Raw 為整體最佳方法，案例分析以 VGG16 Raw Top 100 與人工 Top 100 比較。兩者共同選中的圖片為 24 張，因此 Human-only 與 Model-only 各有 76 張。

表 8：VGG16 Raw 與人工 Top 100 的案例集合

案例類型	集合	數量	分析目的
共同選中	$H \cap M$	24	觀察模型成功捕捉的品質特徵
人工限定	$H - M$	76	觀察模型漏掉的人工重要特徵
模型限定	$M - H$	76	觀察模型可能過度偏好的視覺特徵

8.1 人工與模型共同選中案例 ($H \cap M$)



8.2 人工選中、模型漏掉案例 ($H - M$)



8.3 模型選中、人工未選案例 ($M - H$)



9 結論

本次作業將 Unit7 從二分類擴充為連續品質排序。三個 ImageNet 預訓練模型均以相同的 quality_score、SmoothL1Loss 與訓練設定進行 fine-tuning，並比較 Raw、Confidence-adjusted 與 Ensemble 等排序方法。

在最終人工 Top 100 評估中，VGG16 Raw 表現最佳，Intersection 24、Overlap 0.24、Jaccard 0.1364、AP 0.2674。結果顯示較複雜的 confidence 修正或 ensemble 並不必然優於單一模型直接輸出的排序。尤其 VGG16 的 Confidence 指標反而下降，而 ResNet18 的 Confidence 雖改善 AP，卻未增加 Top 100 的重疊數。

模型排序與人工 Top 100 仍存在明顯差距，表目前模型可能學到部分與清晰度、亮度、對比或構圖相關的捷徑特徵，而未完全掌握『道路資訊完整度』與『障礙物資訊完整度』等實際應用需求。

10 AI 工具使用說明

使用 ChatGPT 跟 Codex 協助環境除錯、Unit7 Ranking 程式與 Shell 腳本建立、CSV 與資料隔離檢查、Regression 訓練流程、TTA confidence、ensemble、Top 100 指標計算、案例分類與報告架構整理。

表 9：AI 工具使用範圍

用途	說明
環境除錯	確認 TWCC NVIDIA PyTorch 24.08、unit7_ngc venv 與 V100 CUDA 執行環境
程式與腳本	協助建立 dataset、models、train_ranking、score_images、ranking 與 evaluation scripts
資料檢查	協助檢查 320/80/100 資料隔離、欄位、圖片路徑、NaN 與重複 image_id
指標分析	利用 AI 協助解讀 Overlap、Jaccard、AP、Confidence 與 Ensemble 差異，並分析可能原因
人工負責內容	人工評分、執行命令、確認輸出、案例圖片選取與最終視覺判讀跟報告撰寫

<https://wandb.ai/mike2006-national-chung-cheng-university/training-unit7-ranking/runs/4iwa4fiy?nw=nwusermike2006>